

TD6 : ESTIMATION DANS UN PROBLÈME DE SONDAGE

Exercice 1. (Problème de sondages) Soit N le nombre d'habitants d'une commune. Il s'agit de faire un sondage de popularité de deux candidats (candidat A et candidat B) qui se présentent aux élections municipales. On choisit un échantillon de n habitants auxquels on pose la question : "Pour qui voteriez-vous aux élections ?" A l'issue de ce sondage, on obtient les données X_1, \dots, X_n , où

$$X_i = \begin{cases} 1, & \text{si le } i^{\text{ème}} \text{ habitant questionné préfère le candidat } A, \\ 0, & \text{si le } i^{\text{ème}} \text{ habitant questionné préfère le candidat } B, \end{cases} \quad i = 1, \dots, n.$$

Pour les raisons évidentes, il est impossible de questionner tous les habitants. Donc $n < N$ (dans la pratique, on a toujours $n \ll N$). Notons θ la part d'habitants de la commune qui préfèrent le candidat A . Le but du sondage est d'estimer θ et de donner un intervalle confiance pour θ .

Définissons les valeurs déterministes x_1, \dots, x_N par

$$x_j = \begin{cases} 1, & \text{si le } j^{\text{ème}} \text{ habitant préfère le candidat } A, \\ 0, & \text{si le } j^{\text{ème}} \text{ habitant préfère le candidat } B, \end{cases} \quad j = 1, \dots, N.$$

On a alors

$$\theta = \frac{1}{N} \sum_{j=1}^N x_j.$$

Définissons aussi

$$\sigma^2 = \frac{1}{N} \sum_{j=1}^N (x_j - \theta)^2.$$

On appelle θ *moyenne de population* et σ^2 *variance de population*.

1. Proposer un modèle statistique pour ce problème. Pour cela,

(a) Calculer $\mathbf{P}_\theta((X_1, X_2, X_3, X_4) = (0, 1, 1, 0))$ en utilisant le fait qu'il s'agit d'un tirage au hasard sans remise d'une population de taille N , car chaque habitant peut apparaître au maximum une fois dans l'échantillon.

(b) Soit $(a_1, \dots, a_n) \in \{0, 1\}^n$ tel que $a_1 + \dots + a_n = a$. Deviner la forme de

$$\mathbf{P}_\theta((X_1, \dots, X_n) = (a_1, \dots, a_n))$$

et prouver la formule obtenue par récurrence sur n .

2. Montrer que $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ est un estimateur sans biais de θ .

3. Montrer que

$$\mathbf{Cov}(X_i, X_j) = -\frac{\sigma^2}{N-1} \quad \text{pour } i \neq j \quad \text{et} \quad \mathbf{Var}(\bar{X}_n) = \frac{\sigma^2}{n} \left(1 - \frac{n-1}{N-1}\right).$$

4. Calculer $\mathbb{E}[s_n^2]$, où $s_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$, et proposer un estimateur sans biais \hat{v}_n^2 de la variance $\text{Var}(\bar{X}_n)$.
5. On se place maintenant dans le cadre asymptotique où $N \rightarrow \infty$, $n = n(N) \rightarrow \infty$ et $n/N \rightarrow 0$.
- (a) Montrer que \bar{X}_n et \hat{v}_n^2 sont des estimateurs consistants de θ et σ^2 .
- (b) On admet que $\sqrt{n}(\bar{X} - \theta)$ converge en loi vers $\mathcal{N}(0, \sigma^2)$. Démontrer la normalité asymptotique
- $$\sqrt{n} \frac{\bar{X}_n - \theta}{\hat{v}_n} \xrightarrow[n \rightarrow \infty]{\mathcal{L}} \mathcal{N}(0, 1).$$
- (c) En utilisant le résultat ci-dessus, trouver un l'intervalle aléatoire $[A, B]$ tel que
- $$\lim_{n \rightarrow \infty} \mathbf{P}([A, B] \text{ contient } \theta) = 95\%.$$
6. *Application numérique* : donner l'intervalle de confiance de niveau asymptotique 95% pour θ lorsque $N = 8000$, $n = 100$, $n_1 = \sum_{i=1}^n \mathbb{1}\{X_i = 1\} = 65$.

Exercice 2. (facultatif) Soient f et g deux densités de probabilité définies sur $[0, 1]$. On suppose que

$$f(x) \leq M g(x), \quad \forall x \in [0, 1]. \quad (1)$$

Soient $\{(X_i, U_i) : i \in \mathbb{N}^*\}$ une suite de variables aléatoires iid telles que

- la loi de X_1 a pour densité g ,
- U_1 est de loi uniforme sur $[0, 1]$,
- X_1 et U_1 sont indépendantes.

On définit les variables aléatoires

$$N = \min \{n : f(X_n) \geq M U_n g(X_n)\}, \quad Y = X_N.$$

1. Soit $q = \mathbf{P}(f(X_n) \geq M U_n g(X_n))$. Montrer que $q = 1/M$.
2. Montrer que N suit la loi géométrique de paramètre q , c'est-à-dire

$$\mathbf{P}(N = k) = (1 - q)^{k-1} q, \quad k \in \mathbb{N}^*.$$

3. Pour toute fonction mesurable bornée $h : [0, 1] \rightarrow \mathbb{R}$, montrer que

$$\mathbb{E}[h(Y)] = \int_0^1 h(y) f(y) dy. \quad (2)$$

En déduire que Y a pour densité f .

Remarque Cet exercice montre que si (1) est vrai et si on est capable de générer des variables aléatoires de densité g , alors on sera également capable de générer des variables aléatoires de densité f . Cette méthode porte le nom de méthode d'acceptation-rejet. Elle a toutefois un inconvénient : le nombre moyen de tirage de X_i nécessaire pour calculer Y est $\mathbb{E}[N] = M$. Ce nombre peut être excessivement grand lorsque M est trop grand.